Homework 4: LSH

108062608 黄柏翰

Map Reduce Algorithm and Code

為了後續的多個 Hash function,檔案中的 prime.txt 是為了讀取 hash function 中所需的質數部分

此次作業的程式碼分成4個部分:

前處理 -> shingle -> Min Hash -> Reduce -> 找出top 10 similar

前處理:做 shingle 的前處理,以及 hash function 的準備

Shingle

先將文章取出三個字為一組的 element, 再將其放到 dictionary, 最後利用查找的方式 assign 存在的 index 值為一

程式碼

Min Hash

將 shingle result, 利用 hashing 找出對應新的順序,並和其 shingle 結果相乘找 min 即為 signature

程式碼

LSH

為利用 MinHash 做好的 signature 做 LSH, 將 candidate pair 的 signature 以 jaccard similarity 的方式量測相似度

程式碼

找出 top 10 similar:

最後寫入 output.txt

Column 表示

Article number, Article number, similarity

```
(12,20):1.0
(47,49):0.74
(30,35):0.72
(23,38):0.57
(48,49):0.49
(47,48):0.34
(14,40):0.31
(23,48):0.14
(23,47):0.08
(9,22):0.08
```